

المستخلص

قدّم معيار SQL:2016 جملة MATCH_RECOGNIZE لدعم التعرف على أنماط الصفوف، وهي تُستخدم للبحث عن نمط محدد داخل أقسام مرتبة من الصفوف باستخدام تعبيرات نمطية، مما يتيح لمحللي البيانات اكتشاف الأنماط وفقاً لنمط يحدده المستخدم. وتبرز أهمية هذه الإمكانية في مجالات عديدة مثل كشف الاحتيال ومراقبة إنترنت الأشياء وتحليل الأسواق وسلاسل النقرات في التجارة الإلكترونية، حيث تتمثل المعلومات المهمة غالباً في سلسلة من الأحداث لا في سجل منفرد. وتوفّر أنظمة قواعد البيانات مثل Oracle وTrino هذه الخاصية، بينما تفتقر مكتبة Pandas إلى دعم أصيل لها، فليجأ المحللون إلى محركاتها عبر الأعمدة المراحة والحلقات اليدوية وإدارة الحالة المخصصة، مما يجعل الشيفرة أطول وأقل قابلية للقراءة وأكثر عرضة للأخطاء. ولسدّ هذه الفجوة، يقوم المحرّك المقترح بتحليل استعلامات MATCH_RECOGNIZE المكتوبة بلغة SQL من نص، وبناء تمثيل منظم للاستعلام، والتحقّق من صحة جمل أنماط الصفوف المدعومة، وترجمة تعبيرات النمط إلى آلات منتهية، وتنفيذ المطابقة الناتجة على أقسام DataFrame المرتبة، بما يغطّي نطاق الخاصية R010 المُقيّمة: PARTITION BY، ORDER BY، PATTERN، DEFINE، وMEASURES وأنماط التخطي وأنماط الإخراج والمحددات الكمية والتناوب والتجميع والمراسي والاستثناءات والتباديل ودوال تتعلّق وتجميع مختارة. وقد اجتازت جميع اختبارات الانحدار البالغ عددها 709 اختباراً. وجرى تقييم النظام بخمس طرق: صحة النتائج مقارنة بالخرجات المرجعية لنظامي Oracle وTrino، وتغطية خصائص المعيار، وسهولة الاستخدام، وتجارب الأداء وقابلية التوسّع. استخدم القياس المرجعي بين الأنظمة بيانات منتجات أمازون بالملكة المتحدة لعام 2023، بدءاً من مقاطع بحجم مئة ألف صف وحتى المجموعة الكاملة البالغة 2.22 مليون صف، بينما استخدم اختبار قابلية التوسّع مجموعة تقييمات أمازون لعام 2023 الأكبر حجماً حتى 227.9 مليون صف، تحت نواة معالج واحدة وحدّ للذاكرة قدره 58 جيجابايت. وقد أعاد المحرّك إنتاج المخرجات المرجعية صفّاً بصفّ في جميع خلايا المقارنة الثلاثين بين الأنظمة، وسجّل، تحت نواة معالج واحدة وحدّ للذاكرة قدره 32 جيجابايت، أدنى متوسط زمن تنفيذ بين الأنظمة الثلاثة المقارنة (0.17 ثانية مقابل 1.04 ثانية لنظام Oracle و1.98 ثانية لنظام Trino)، مع قابلية توسّع شبه خطية، وظلّ متقدّماً على قاعدتي البيانات حتى 227.9 مليون صف. وأكمل المحرّك ونظام Oracle الحالات الخمس والثلاثين جميعها، بينما أكمل Trino ثلاثاً وثلاثين حالة. وتُظهر هذه النتائج أنّ جلب وظيفة MATCH_RECOGNIZE إلى Pandas يمكن أن يجسر بين مسارات عمل SQL وPython، ويجعل تحليل البيانات التسلسلية أكثر قابلية للقراءة والنقل والإنتاجية.

الكلمات المفتاحية: التعرف على أنماط الصفوف؛ مطابقة الأنماط؛ الآلات المنتهية؛ تحليل البيانات التسلسلية؛ الاستعلامات التصريحية؛ إطارات البيانات.

جامعة النيل الأهلية

كلية تكنولوجيا المعلومات وعلوم الحاسب

برنامج المعلوماتية

استخراج أنماط السجلات التسلسلية

تعزيز إطارات بيانات بانداس بتنفيذ آلية التعرف على الأنماط

أطروحة مقدمة إلى كلية تكنولوجيا المعلومات وعلوم الحاسب بجامعة النيل الأهلية للحصول على

درجة ماجستير العلوم في المعلوماتية

إعداد

منير أشرف منير لواندي

إشراف

أ.د. محمد الحلو

أ.د. أحمد عوض

جامعة النيل الأهلية

أغسطس 2026