

الملخص

قدّم معيار SQL:2016 جملة MATCH_RECOGNIZE للتعرف على أنماط الصفوف، وهي تبحث عن نمط محدد داخل أقسام مرتّبة من الصفوف باستخدام تعبيرات نمطية. وتبرز أهميتها في مجالات مثل كشف الاحتيال ومراقبة إنترنت الأشياء وسلاسل النقرات في التجارة الإلكترونية، حيث تتمثل المعلومة المهمة في سلسلة من الأحداث لا في سجلٍ منفرد. وتوفّر أنظمة مثل Oracle و Trino هذه الخاصية، بينما تفتقر مكتبة Pandas إلى دعمٍ أصيل لها، فليجأ المحللون إلى الأعمدة المزاحة والحلقات اليدوية وإدارة الحالة المخصصة، مما يجعل الشيفرة أطول وأقلّ قابلية للقراءة وأكثر عرضة للأخطاء. ولسدّ هذه الفجوة، يقوم المحرّك المقترح بتحليل استعلامات MATCH_RECOGNIZE المكتوبة بلغة SQL، وبناء تمثيلٍ منظم لها، والتحقّق من صحة جملها، وترجمة تعبيرات النمط إلى آلاتٍ منتهية، وتنفيذ المطابقة على أقسام DataFrame المرتّبة، بما يغطّي نطاق الخاصية R010 المُقيّمة: PARTITION BY و ORDER BY و PATTERN و DEFINE و MEASURES وأنماط التخطي والإخراج والمحددات الكمية والتناوب والتجميع والاستثناءات والمراسي والتباديل ودوال تنقّل وتجميع مختارة. وقد اجتازت جميع اختبارات الانحدار البالغ عددها 709 اختباراً. وجرى التقييم بخمسة معايير: صحة النتائج مقارنةً بمخرجات Oracle و Trino، وتغطية خصائص المعيار، وسهولة الاستخدام، والأداء، وقابلية التوسّع. استخدم القياس المرجعي بيانات منتجات أمازون بالمملكة المتحدة لعام 2023 حتى 2.22 مليون صف، واستخدم اختبار قابلية التوسّع تقييمات أمازون لعام 2023 حتى 227.9 مليون صف تحت نواة معالج واحدة وحدّ للذاكرة قدره 58 جيجابايت. وأعاد المحرّك إنتاج المخرجات المرجعية صفّاً بصفّ في خلايا المقارنة الثلاثين جميعها، وسجّل، تحت نواة معالج واحدة وحدّ للذاكرة قدره 32 جيجابايت، أدنى متوسط زمن تنفيذ بين الأنظمة الثلاثة: 0.17 ثانية مقابل 1.04 ثانية لنظام Oracle و 1.98 ثانية لنظام Trino، مع قابلية توسّع شبه خطية. وأكمل المحرّك ونظام Oracle الحالات الخمس والثلاثين جميعها، بينما أكمل Trino ثلاثاً وثلاثين حالة. وتظهر هذه النتائج أنّ جلب وظيفة MATCH_RECOGNIZE إلى Pandas يمكن أن يجسر بين مسارات عمل SQL و Python، ويجعل تحليل البيانات التسلسلية أكثر قابلية للقراءة والنقل.

الكلمات المفتاحية: التعرف على أنماط الصفوف؛ مطابقة الأنماط؛ الآلات المنتهية؛ تحليل البيانات التسلسلية؛ الاستعلامات التصريحية؛ إطارات البيانات.

استخراج أنماط السجلات التسلسلية: تعزيز إطارات بيانات بانداس بتنفيذ آلية التعرف على الأنماط

إعداد

منير أشرف منير لوندي

رسالة مقدمة إلى كلية تكنولوجيا المعلومات وعلوم الحاسب، جامعة النيل الأهلية

كجزء من متطلبات الحصول على درجة

ماجستير العلوم

في

المعلوماتية

لجنة الإشراف:

المشرف الرئيسي

أ.د. محمد الحلوة، أستاذ بكلية تكنولوجيا المعلومات وعلوم الحاسب، جامعة النيل الأهلية

مشرف

د. أحمد عوض، أستاذ مشارك بالجامعة البريطانية في دبي، الإمارات، وجامعة القاهرة، مصر

استخراج أنماط السجلات التسلسلية: تعزيز إطارات بيانات بانداس بتنفيذ آلية

التعرف على الأنماط

إعداد

منير أشرف منير لوندي

رسالة مقدمة إلى كلية تكنولوجيا المعلومات وعلوم الحاسب، جامعة النيل الأهلية

كجزء من متطلبات الحصول على درجة

ماجستير العلوم

في

المعلوماتية

تاريخ

سبتمبر/2026